



Solución del Reto

Inteligencia artificial avanzada para la ciencia de datos I

Arah Rojas Blanco | A00834299

Valeria Aguilar Meza | A01741304

Mariela Quintanar de la Mora | A0164267

Miguel Angel Barrientos Ballesteros | A01637150





Introducción al problema

En este reto resolveremos un problema real de inteligencia artificial siguiendo la metodología CRISP-DM. Durante estas seis semanas estuvimos trabajando en la preparación de datos relacionados a transacciones fraudulentas, para entrenar diversos modelos, con la finalidad de evaluar su desempeño y elegir aquel adecuado para la clasificación de transacciones y la detección de fraudes.





BAF

El Bank Account Fraud (BAF) Dataset, es un conjunto de seis datasets utilizados para evaluar métodos de machine learning y fair ML. Se caracteriza por ser realista, sesgado, desbalanceado y dinámico.





(6240, 62)		
	fraud_bool	income
0	0	0.3
1	0	0.8
2	0	0.8
3	0	0.6
4	0	0.9
...
6235	0	0.6
6236	0	0.9
6237	0	0.8
6238	0	0.9
6239	0	0.2
current_address_mont		
0		
1		
2		
3		

Dataset

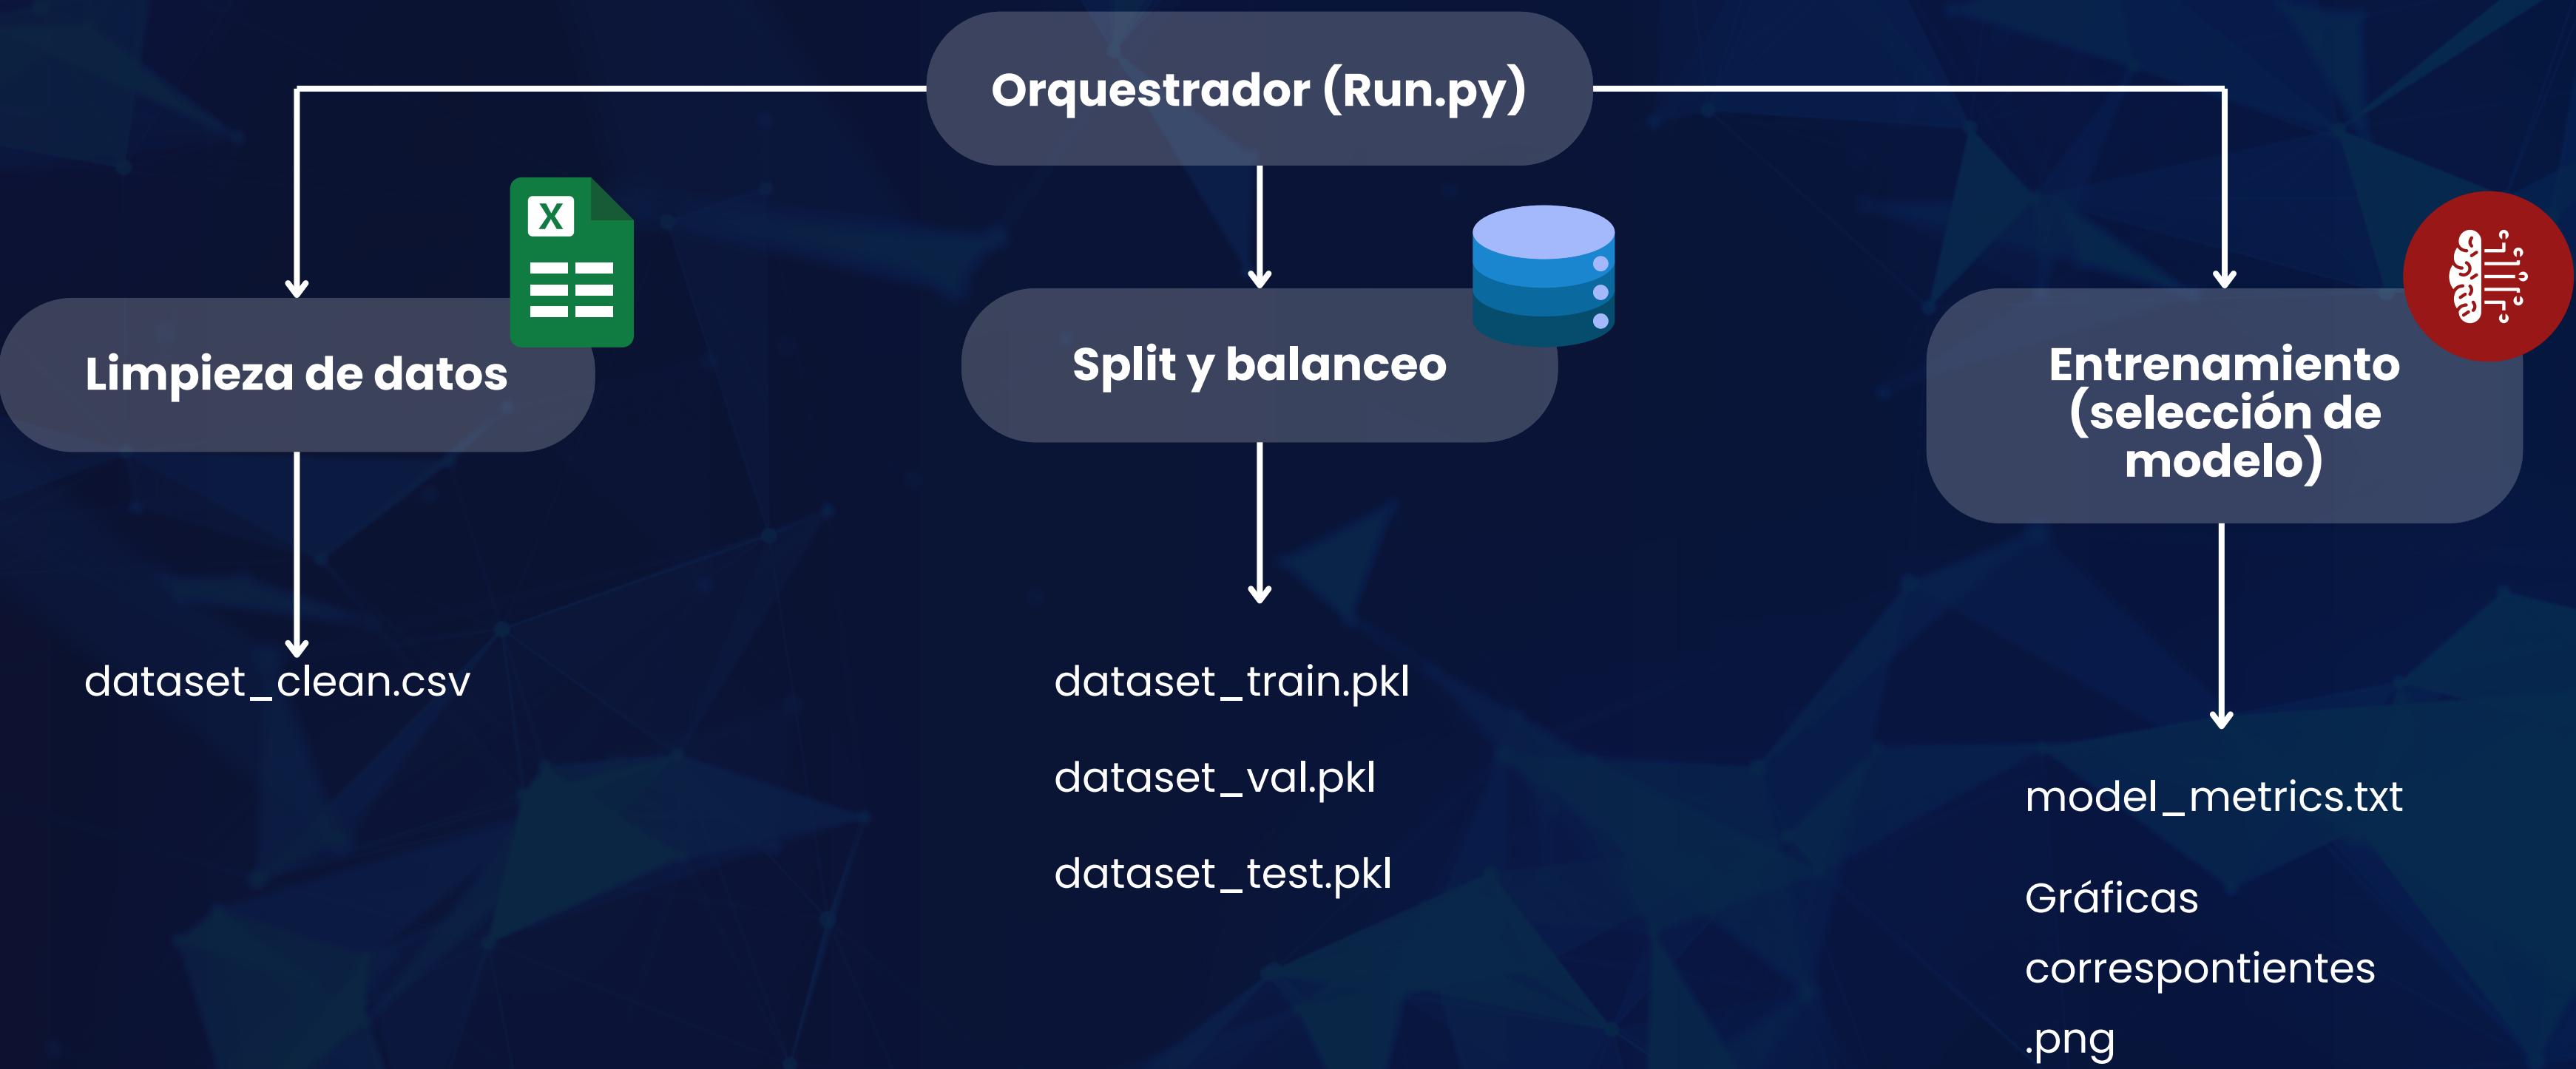
Contiene información del cliente y del dispositivo (edad, ingresos, dirección, historial, uso de internet/teléfono, sistema operativo, etc.).

Su propósito es detectar patrones que permitan identificar intentos de fraude en cuentas bancarias.

Filas: transacciones

target: fraud_bool

Pipeline Overview





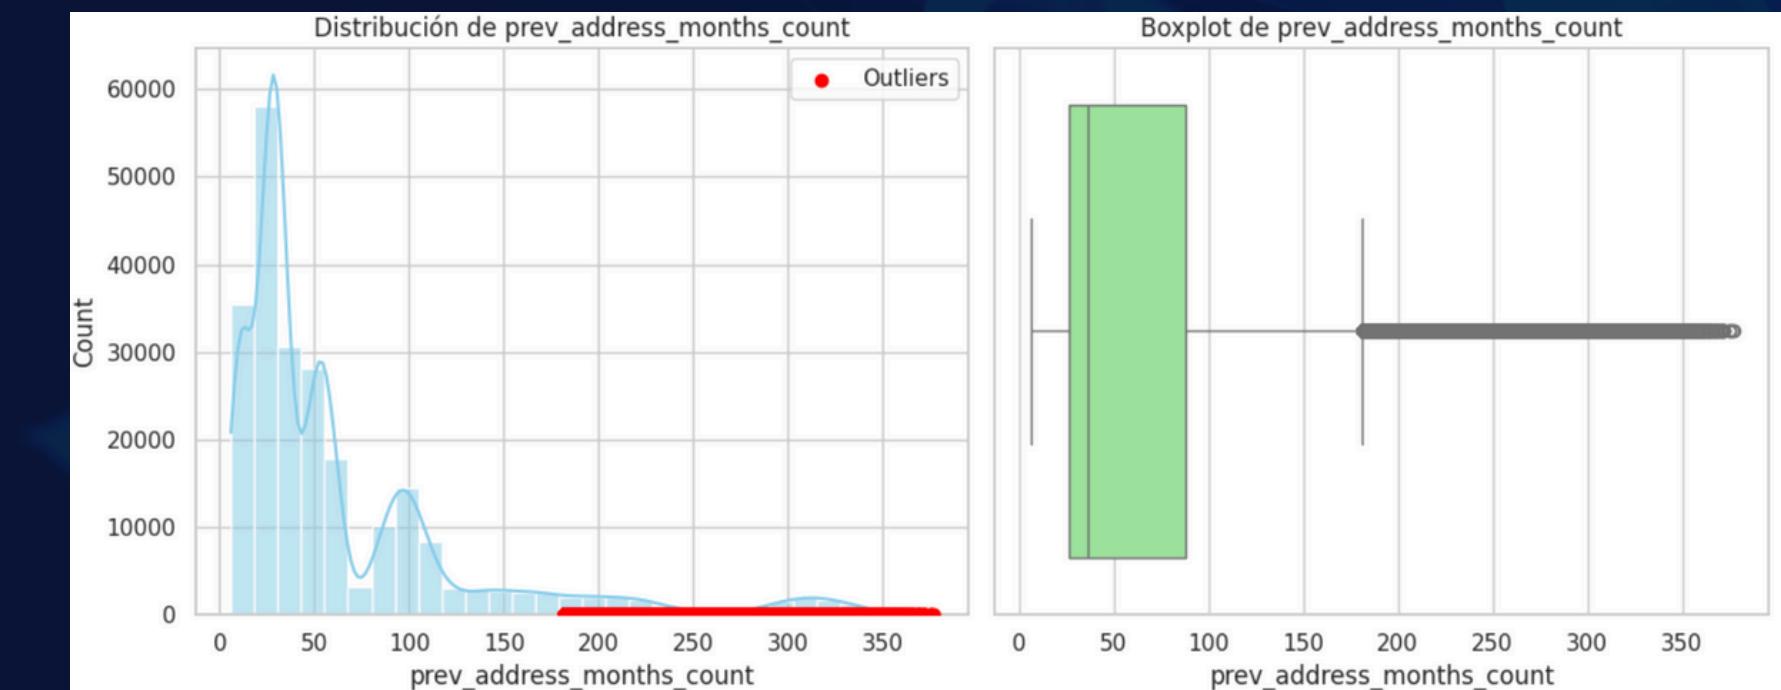
Limpieza de datos

Revisión de datos

Num. de variables, Num. de filas y columnas, tipos de datos, valores faltantes, etc.

Conversión de valores nulos

Convertir valores fuera de rango en NaN



Detección de outliers

Buscamos los outliers en las variables numéricas, considerando registros de no fraude.



Transformaciones

Probamos transformaciones en todos los registros y nos quedamos con la mejor para cada variable
(yeo johnson, log1p, log10, sqrt)

Imputar valores NaN

En columnas donde 0 significa “no aplica/ausente”, en las demás numéricas con NaN, se imputa con la mediana de la columna

Codificación de variables categóricas

ONE-HOT ENCODING para categóricas

Descargar

Se exporta el archivo limpio a csv



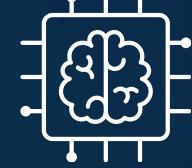
Split de datos

Temporal por mes :

- TRAIN: meses 0–4 → el modelo aprende.
- VALID: mes 5 → early stopping y ajuste de hiperparámetros.
- TEST: meses 6–7 → evaluación y métricas finales.

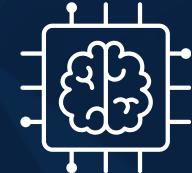


Modelos implementados



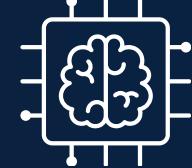
XGBoost

Algoritmo de boosting basado en árboles de decisión que construye modelos de manera secuencial, corrigiendo los errores de iteraciones anteriores para mejorar la precisión y eficiencia



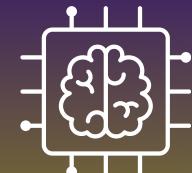
Red Neuronal Multicapa

Modelo de aprendizaje profundo compuesto por múltiples capas de neuronas interconectadas que aprenden representaciones no lineales para resolver problemas de clasificación y regresión.



Random Forest

Algoritmo de ensamble basado en árboles de decisión que construye múltiples árboles de manera independiente y combina sus predicciones para mejorar la precisión y reducir el sobreajuste



LightGBM ← Algoritmo Final

Algoritmo de boosting basado en árboles de decisión que utiliza técnicas de histogramas y crecimiento por hojas para entrenar de forma rápida y eficiente, manteniendo alta precisión en clasificación y regresión.



LightGBM

Light Gradient Boosting Machine

- **Árboles de decisión secuenciales:** cada nuevo árbol corrige los errores (residuos) de los árboles anteriores.
- **Gradiente descendente** para optimizar una función de pérdida binary_logloss
- **Cross entropy** para medir el error.



LightGBM

Light Gradient Boosting Machine

Configuración usada:

- Complejidad → **num_leaves = 63**
- Robustez → **min_data_in_leaf = 80**
- Regularización → **lambda_l2 = 2.0 (Ridge)**
- Prevención de sobreentrenamiento → **early_stopping = 100**

Modelo seleccionado para la solución del problema

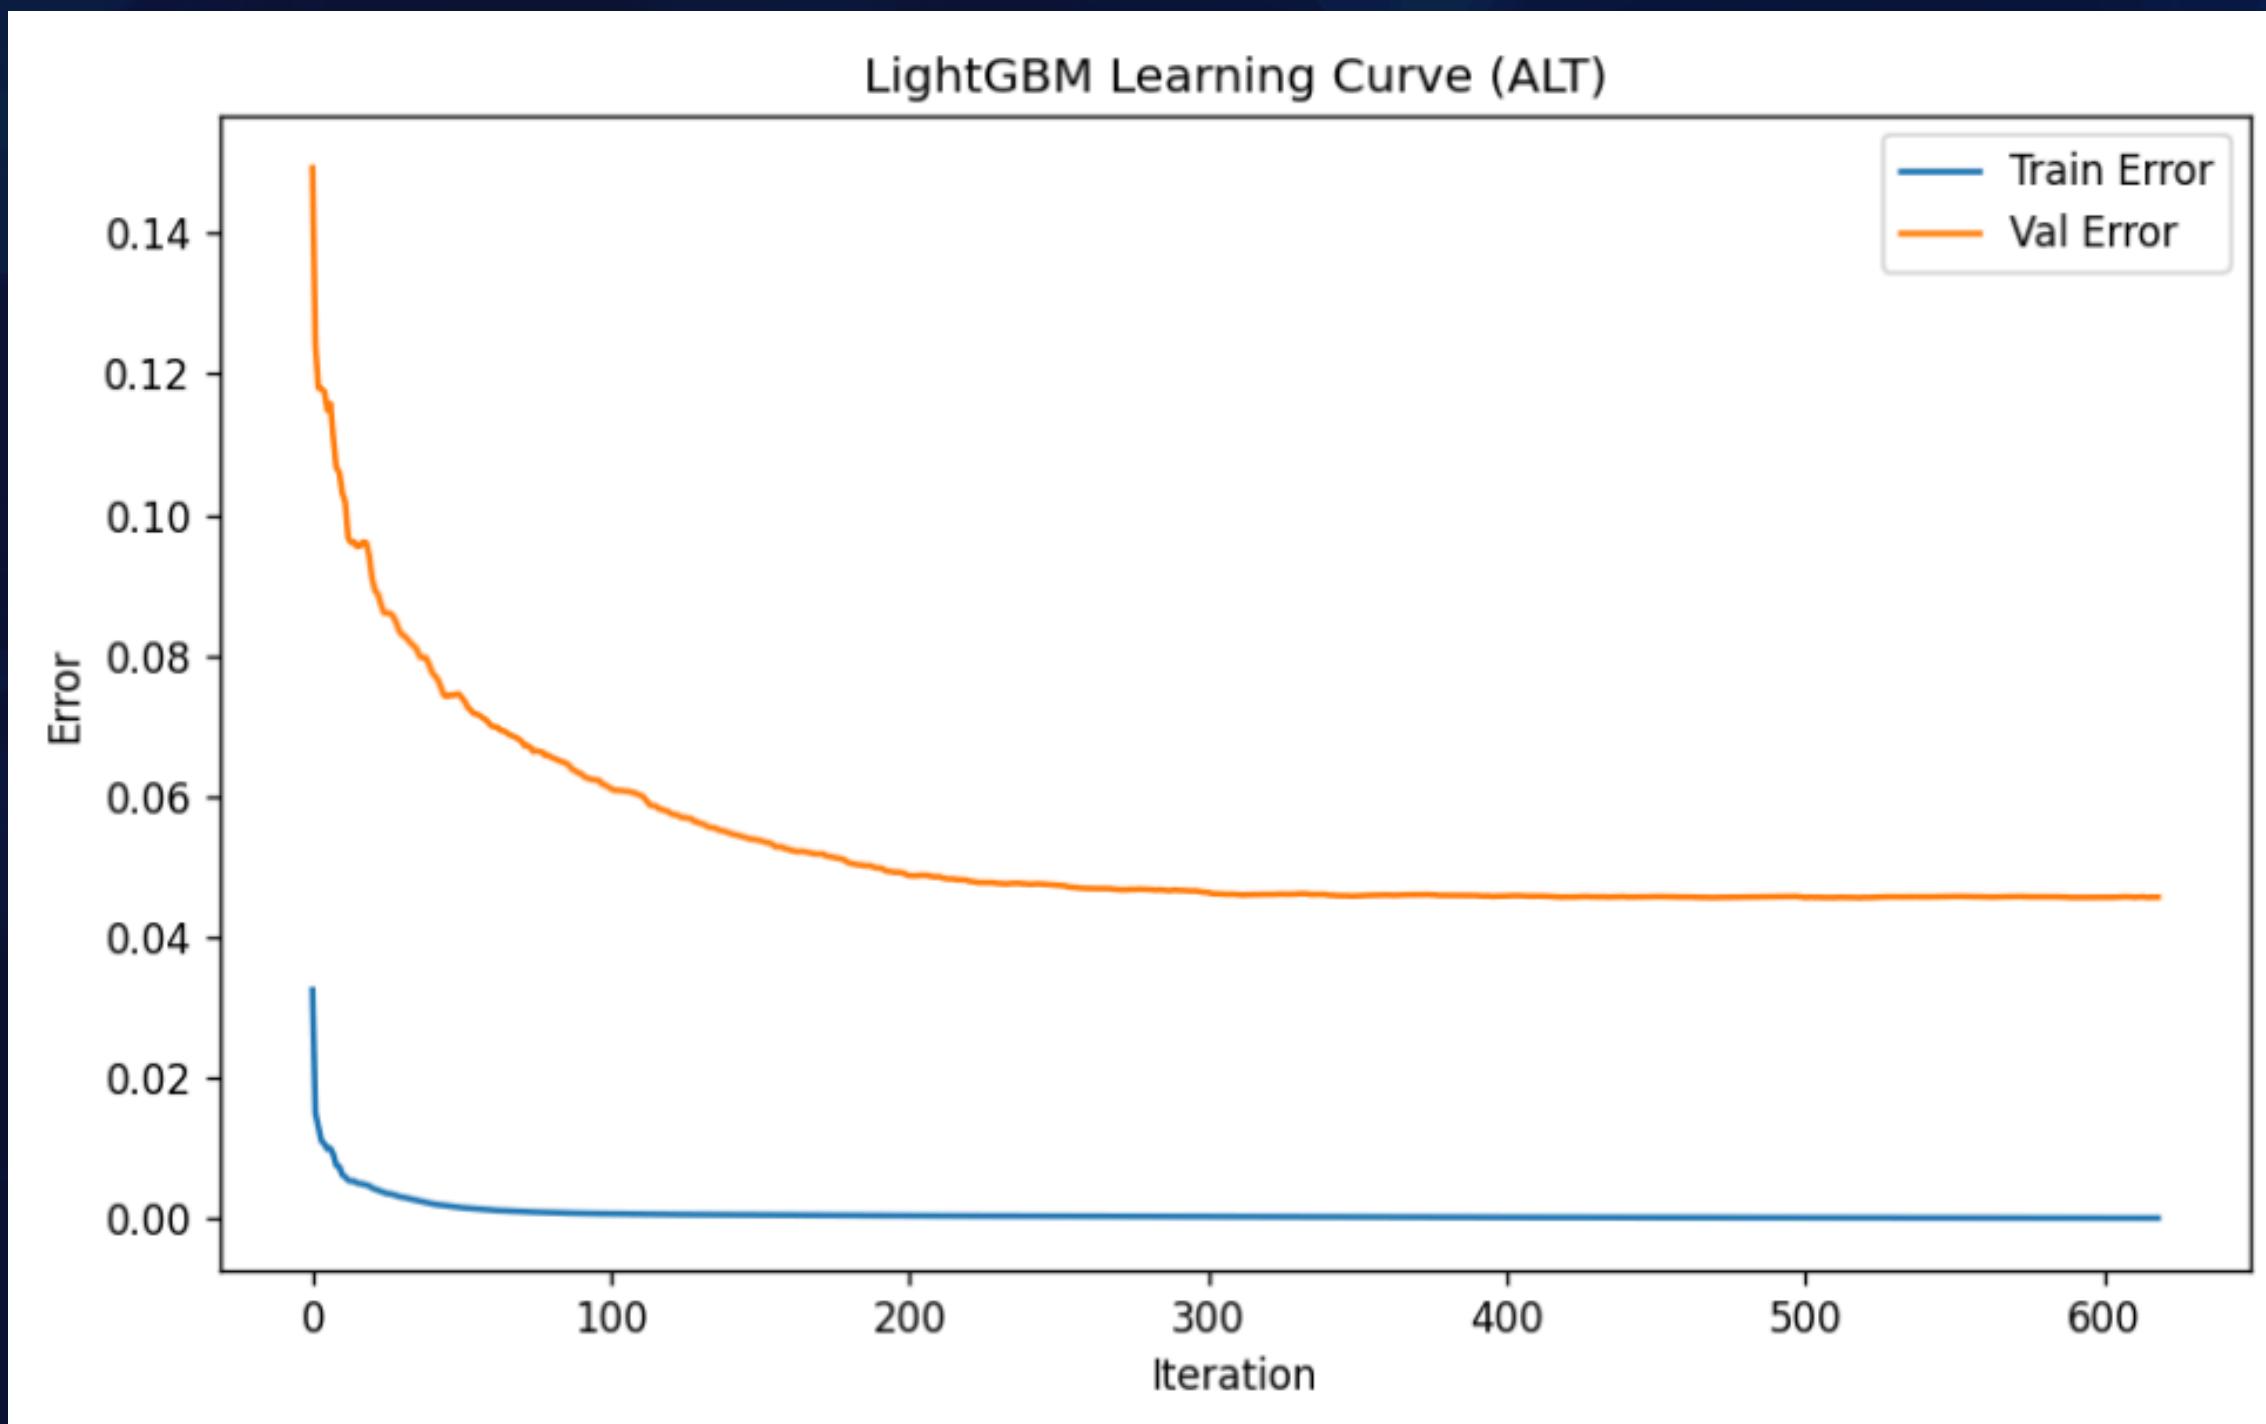


Mejores métricas (Test)

- AUC (Base / Alt): 0.9540 / 0.9537
- Accuracy (Base / Alt): 0.9424 / 0.9440
- F1 (Base / Alt): 0.2271 / 0.2299
- **Recall@5%FPR (Base / Alt): 0.7711 / 0.7621**
- **FPR_real: 0.0557**
- thr(valid) (Base / Alt): 0.031238 / 0.027630
- best_iteration (Base / Alt): 592 / 519



Sesgo



Nivel:

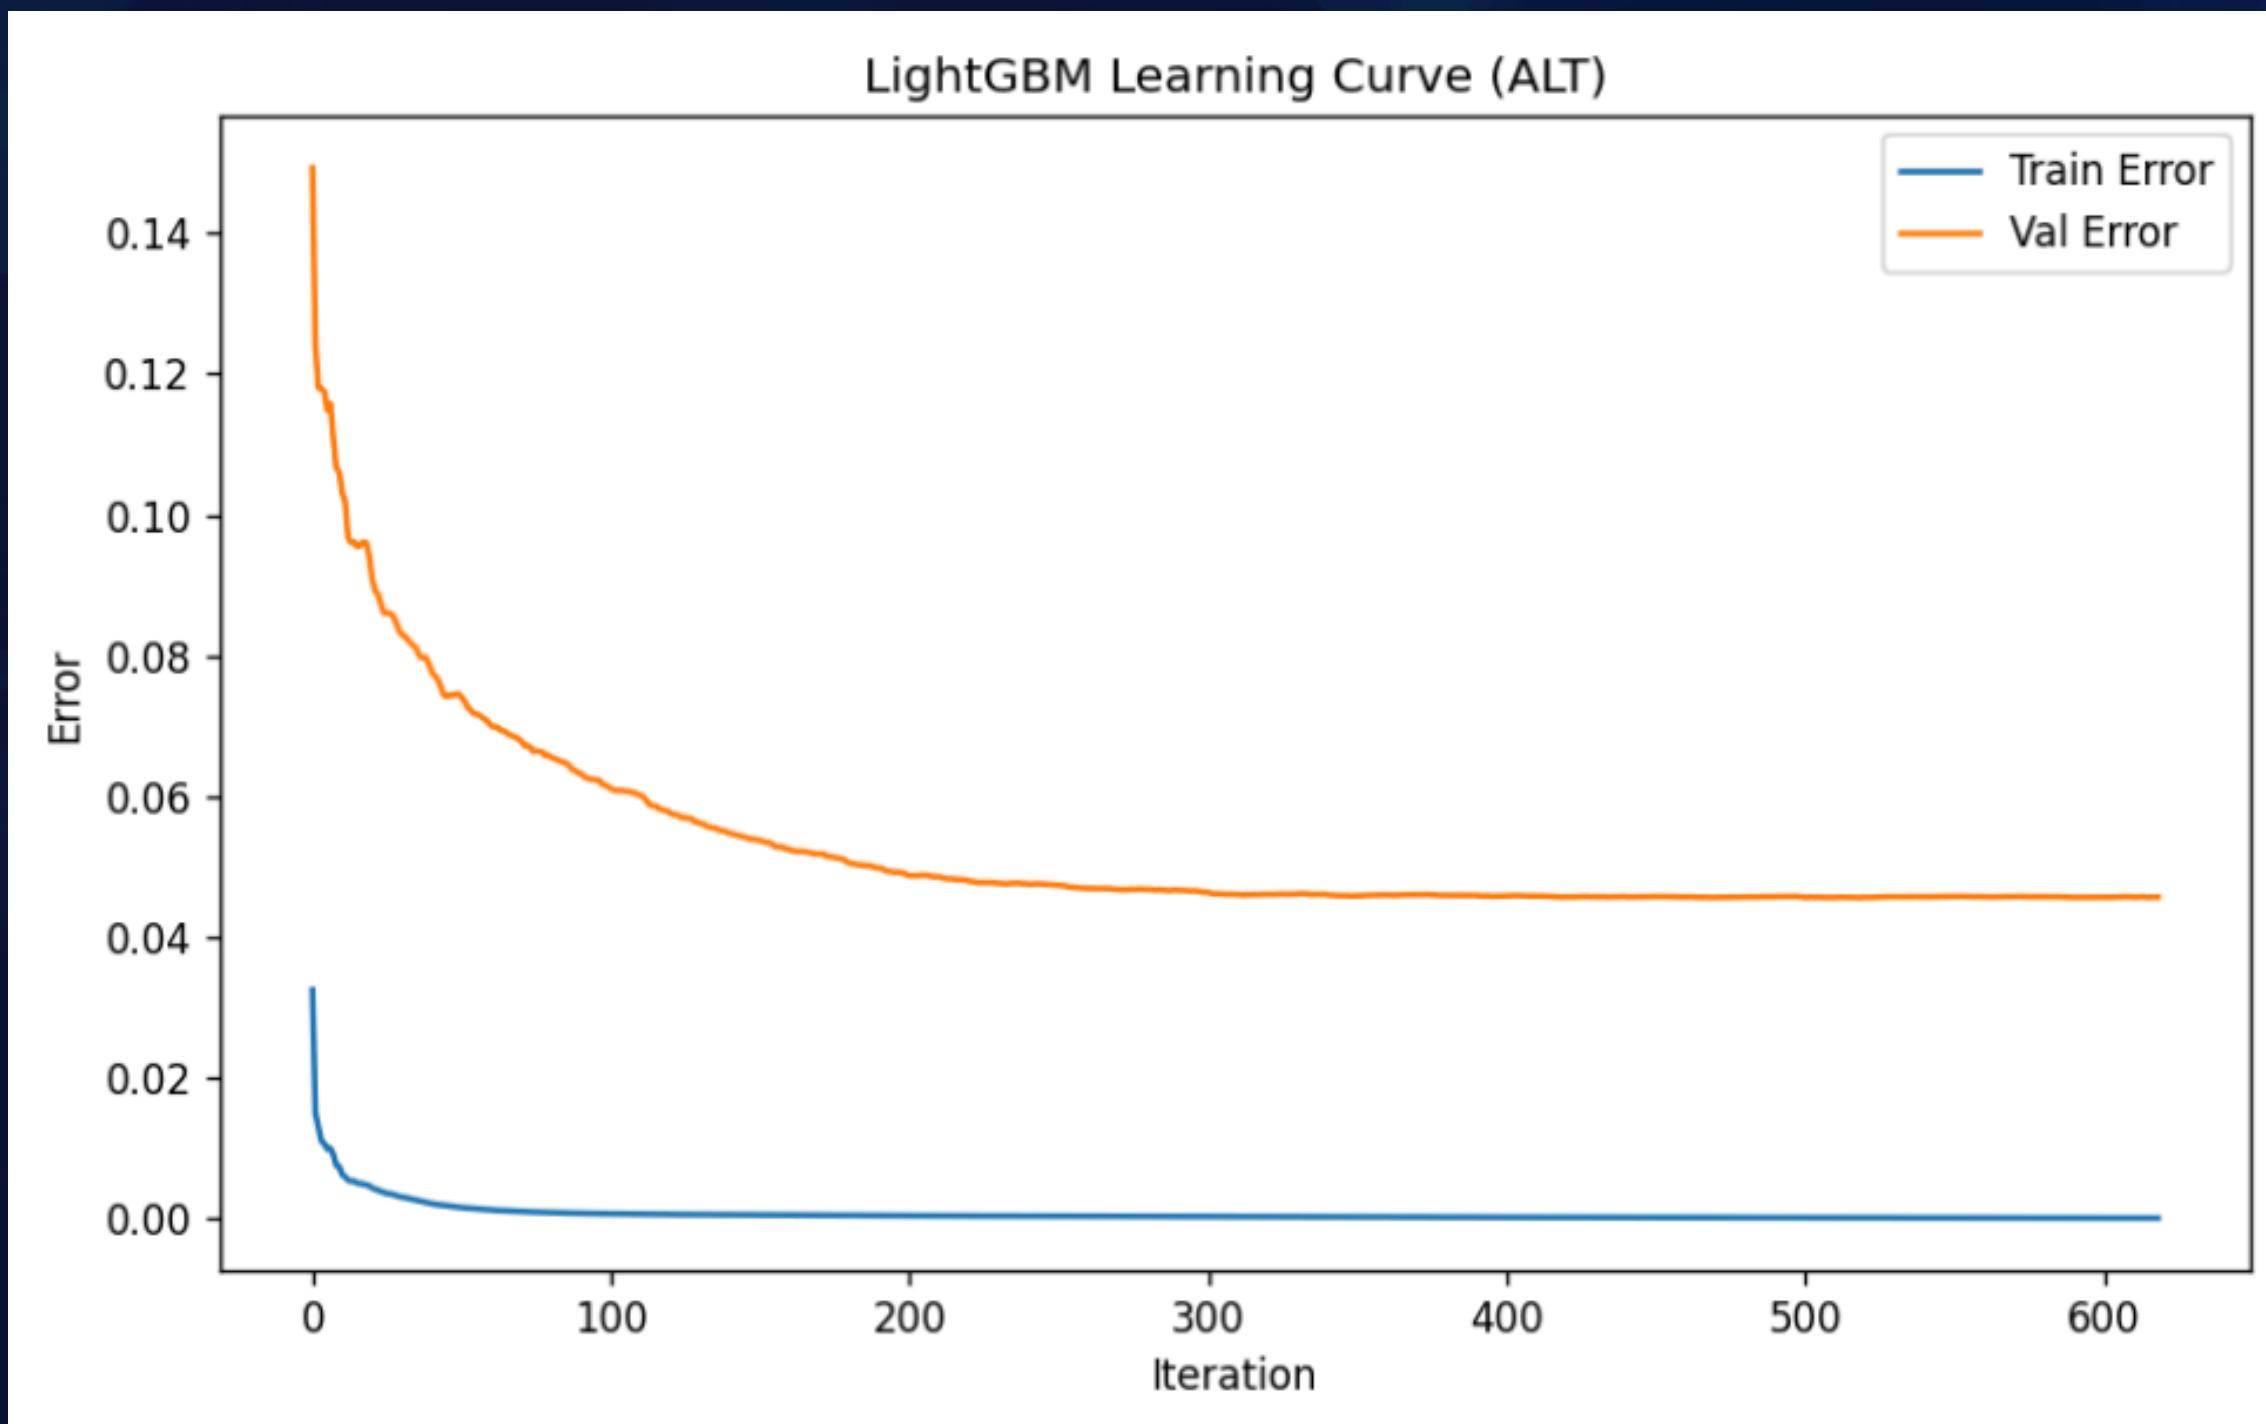
- Muy bajo en train
- Moderado en val

Conclusión:

- Bajo nivel de sesgo en el modelo: no hay señales de underfitting



Varianza



Gap entre conjuntos:

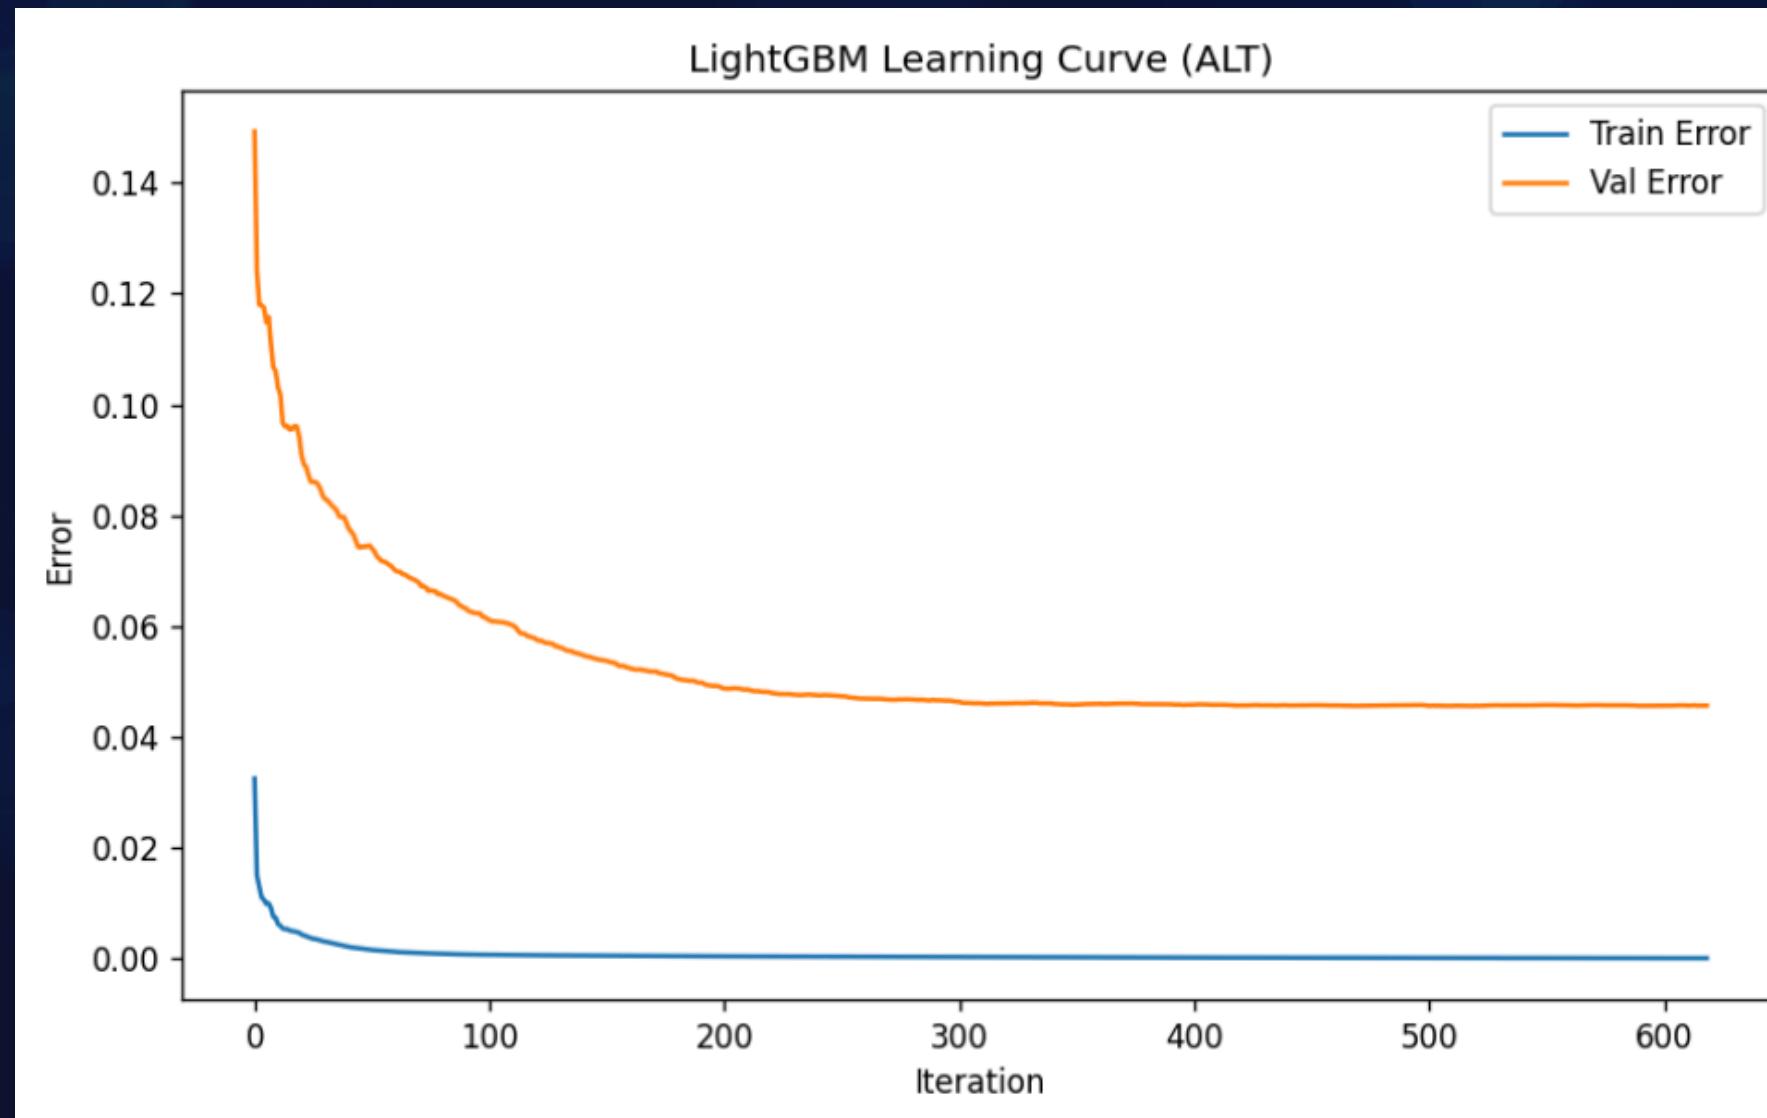
- Considerable, no mejora con las iteraciones después de 200.

Conclusión:

- **Moderado** nivel de varianza.



Ajuste del modelo



- F1 (Base / Alt): 0.2271 / 0.2299
- Recall@5%FPR (Base / Alt): 0.7711 / 0.7621
- FPR_real: 0.0557

Señales de underfitting:

- Bajas

Señales de overfitting:

- moderadas

Conclusión:

- **Buen ajuste**, tendiendo al overfitting.

Se priorizan los falsos positivos frente a los falsos negativos.



Desafíos y correcciones

- **Overfitting:** La mayoría de los datos presentaban grandes valores de accuracy, los cuales sin embargo no se mostraban en matrices de confusión así como metricas de f1 y recall. Técnicas de balanceo así como regularizaciones fueron utilizadas para mejorar el rendimiento
- **One Hot Encoding:** Esta técnica de preprocessamiento nos presentó dificultades en implementar por su tendencia a crear columnas vacías.
- **Error en evaluación MLP:** Inicialmente no se utilizó adecuadamente el conjunto de test en MLP, lo cual nos mostró falsos resultados muy buenos. Corregir la evaluación mostró que los resultados reales eran peores que LightGBM.

Mejoras futuras

- **Split de datos antes de transformar:** ajustar yeo-johnson solamente con el set de train.
- Probar conjuntos de diferentes variantes (ej. train con base, val con v3, test con v5).
- Identificar variables posibles de **eliminar**.
- Mostrar precisión para resultados más claros

Conclusión

A pesar del reto que representó trabajar con una base de datos severamente desbalanceada, la aplicación de distintos métodos y transformaciones permitió comparar el desempeño de varios modelos. Finalmente, LightGBM destacó como el más preciso y robusto, demostrando ser la mejor opción para enfrentar las particularidades de esta base de datos desafiante.





Muchas Gracias

